

PROJECT PROPOSAL

Project Title: AI-Powered Plagiarism Detection System for Academic Research Papers using BERT and Vector Similarity Search

Student Name: Ma Soe Nandar Htun

Major: Computer Science

[Roll.no.](#) -PaKaPaTa-002735

၁။ Introduction (နိဒါန်း)

ယနေ့ခေတ် ပညာရေးလောကတွင် Digital နည်းပညာထွန်းကားလာသည်နှင့်အမျှ သုတေသနစာတမ်းများကို ကူးယူဖော်ပြခြင်း (Plagiarism) သည် ကြီးမားသော စိန်ခေါ်မှုတစ်ခု ဖြစ်လာသည်။ ထို့အပြင် Large Language Models (LLMs) များ ပေါ်ပေါက်လာခြင်းကြောင့် ကျောင်းသားများသည် ကိုယ်တိုင်ရေးသားခြင်းထက် AI ကို အသုံးပြု၍ ရေးသားခြင်း (AI-generated content) များ ပိုမိုပြုလုပ်လာကြသည်။ ဤ Project သည် ထိုပြဿနာနှစ်ခုလုံးကို တစ်ပြိုင်နက် ဖြေရှင်းနိုင်ရန် ရည်ရွယ်သည်။

၂။ Problem Statement (ပြဿနာရပ်များ)

Semantic Plagiarism: လက်ရှိ Plagiarism Checker အများစုသည် စကားလုံးချင်းတူမှုသာ ဖမ်းမိပြီး၊ အဓိပ္ပာယ်တူ စကားလုံးလွှဲထားခြင်း (Paraphrasing) ကို ထိရောက်စွာ မစစ်ဆေးနိုင်ခြင်း။

AI Writing Rise: ကျောင်းသားများအနေဖြင့် ChatGPT ကဲ့သို့ AI များသုံး၍ ရေးသားထားခြင်းကို ခွဲခြားသိရှိနိုင်ရန် ခက်ခဲခြင်း။

Large Data Management: သုတေသနစာတမ်းပေါင်းများစွာထဲမှ သက်ဆိုင်ရာ အချက်အလက်ကို အချိန်တိုအတွင်း ရှာဖွေနိုင်မှု အားနည်းခြင်း။

၃။ Objectives (ရည်ရွယ်ချက်များ)

BERT (NLP) နည်းပညာကို အသုံးပြု၍ စကားလုံးတူရုံတင်မက အဓိပ္ပာယ်တူပါကပါ ဖမ်းမိနိုင်သော Plagiarism Detector တည်ဆောက်ရန်။

ကျောင်းသားတင်ပြသော စာတမ်းသည် AI (LLM) သုံး၍ ရေးထားခြင်း ဟုတ်၊ မဟုတ် (AI Probability Score) ကို တွက်ချက်ပြသရန်။

Computer Science ဆိုင်ရာ သုတေသနစာတမ်း ၅,၀၀၀ ကျော်ကို အခြေခံ၍ တိကျသော Similarity Report ထုတ်ပေးရန်။

၄။ Methodology & Technical Stack (နည်းပညာပိုင်းဆိုင်ရာ အသုံးပြုမှု)

ဤစနစ်တွင် အောက်ပါ နည်းပညာများကို အသုံးပြုသွားမည်ဖြစ်သည်-

Dataset: S2ORC (Semantic Scholar Open Research Corpus) မှ Computer Science paper များကို အသုံးပြုမည်။

Plagiarism Detection:

Sentence-BERT (SBERT): စာသားများကို Vector အဖြစ်ပြောင်းရန်။

FAISS (Facebook AI Similarity Search): Vector များကို အမြန်ဆုံး ရှာဖွေရန်။

Cosine Similarity: တူညီမှု ရာခိုင်နှုန်းကို တွက်ချက်ရန်။

AI Writing Detection: RoBERTa-based classification model ကို အသုံးပြု၍ AI ရေးသားဟန်ကို ခွဲခြားမည်။

Frontend: Streamlit သို့မဟုတ် React ကို အသုံးပြု၍ Web Interface ပြုလုပ်မည်။

၅။ Expected Outcomes (ရရှိလာမည့် ရလဒ်များ)

Project ပြီးဆုံးပါက အောက်ပါတို့ကို လုပ်ဆောင်နိုင်သော Tool တစ်ခု ရရှိလာမည်-
ကျောင်းသားတင်လိုက်သော စာတမ်းကို Database ထဲရှိ Paper ၅,၀၀၀ ကျော်နှင့် တိုက်စစ်ပေးခြင်း။

Similarity Score % (ခိုးကူးထားသော ရာခိုင်နှုန်း) ကို ပြသပေးခြင်း။

AI Probability Score % (AI ရေးသားဟန် ဖြစ်နိုင်ခြေ) ကို ဖော်ပြပေးခြင်း။

မူရင်း Paper ၏ အချက်အလက်များကို Reference အဖြစ် ထုတ်ပြပေးခြင်း။

၆။ Conclusion (နိဂုံး)

ဤ Hybrid Plagiarism Checker သည် ကျောင်းသားများ၏ ကိုယ်ပိုင်ဖန်တီးနိုင်စွမ်းကို မြှင့်တင်ပေးနိုင်ရုံသာမက၊ ဆရာမများအနေဖြင့်လည်း စာတမ်းများကို စနစ်တကျနှင့် တိကျစွာ စစ်ဆေးနိုင်စေမည်ဖြစ်သည်။ ဤ Project သည် နောင်တွင် ပိုမိုကြီးမားသော Dataset များနှင့် ချိတ်ဆက်၍ တက္ကသိုလ်အဆင့်အထိ အသုံးပြုနိုင်သော စနစ်တစ်ခု ဖြစ်လာမည်ဟု ယုံကြည်ပါသည်။